Nom – Prénom : Maxime DRÉAN **Date :** Octobre 2026

Reconnaissance acoustique des oiseaux par apprentissage profond

Rapport final de veille technologique

Master 2 – Outils Méthodologiques pour la Recherche et l'Entreprise – Informatique 2349

Résumé – Cette veille compare la reconnaissance directe et le transfert de représentations pour identifier les oiseaux dans des enregistrements naturels. Les publications et les outils disponibles font apparaître trois difficultés : le masquage acoustique, les annotations incomplètes et le changement de domaine. Une expérimentation sur BirdNET 2.4 et 3.0 confronte ces difficultés à des segments annotés et à des perturbations contrôlées. Elle montre une dégradation sous bruit et superposition, ainsi qu'une comparaison des versions sensible au jeu et au seuil. Le choix d'un outil demande donc une validation adaptée au terrain ; la seule architecture ou l'étendue du vocabulaire ne le détermine pas.

Mots-clés – bioacoustique ; BirdNET ; transfert d'apprentissage ; bruit ; polyphonie ; généralisation.

Question de veille – *Dans quelle mesure les modèles d'apprentissage profond permettent-ils de détecter et d'identifier automatiquement les espèces d'oiseaux à partir d'enregistrements réalisés en milieu naturel, malgré le bruit ambiant, les vocalisations simultanées et la variabilité géographique ?*

---

1. Question de veille et périmètre

Le suivi acoustique passif fournit des enregistrements répétés sans observation continue sur le terrain. Leur analyse manuelle limite le volume exploitable. L'apprentissage profond automatise une partie de l'identification, mais une liste d'espèces prédites doit encore être confrontée aux vocalisations présentes pour servir un suivi écologique [1, 2].

La question initiale associait le bruit, les vocalisations simultanées et la variabilité géographique. Ces trois axes sont conservés dans la veille. Le volet expérimental s'est précisé : l'exploration de sons Xeno-canto a été complétée par une comparaison sur des paysages sonores annotés, puis par des perturbations avec témoins. Cette évolution répond à la difficulté d'interpréter un score sans référence suffisante. L'étude porte sur les chants et les cris, sans localisation spatiale, estimation d'abondance ou mesure des limites temporelles des vocalisations. La géographie reste une question documentaire, faute d'un test isolant son effet de celui des espèces et des conditions de collecte.

La sélection part de Stowell, de BirdNET et de BirdSet, puis examine le transfert, l'auto-supervision et les évaluations de terrain. Les critères de comparaison sont les données et objectifs d'apprentissage, les sorties, l'adaptation, l'évaluation et le déploiement. Les articles étayent les résultats ; les dépôts et fiches de modèles documentent les versions, formats et licences. Les travaux sont retenus pour éclairer ces critères, sans viser une revue systématique.

Trois questions guident la comparaison : le modèle couvre-t-il les catégories recherchées, ses représentations peuvent-elles être adaptées, et les conditions d'évaluation correspondent-elles à l'usage envisagé ? Cette distinction évite de confondre un gain sur un jeu de référence avec une amélioration directement transférable au suivi d'un site.

2. Approches disponibles et verrous technologiques

2.1. Reconnaissance directe ou représentations à adapter

BirdNET associe des spectrogrammes à un vocabulaire appris d'espèces [2]. Sa version 2.4 repose sur un réseau de type EfficientNet-B0 ; la documentation des fichiers distribués complète la description du système initial [3, 4]. Perch 2.0 conserve une supervision sur des corpus annotés de plusieurs taxons, avec un EfficientNet-B3. Il produit des scores et des représentations sur des segments de cinq secondes à 32 kHz [5]. La reconnaissance directe évite un entraînement local, tant que les catégories recherchées sont couvertes. Le transfert réutilise au contraire l'encodeur pour apprendre une décision adaptée aux données ou catégories locales. Le tableau 1 résume les usages et adaptations possibles.

Perch 2.0 combine notamment Xeno-canto, iNaturalist, Tierstimmenarchiv et FSD50K. Son apprentissage associe une auto-distillation entre têtes de classification à la prédiction de l'enregistrement source [5]. La supervision ne se réduit donc pas au nom d'espèce. Ses deux sorties permettent d'essayer la classification distribuée, puis de réutiliser l'encodeur si les catégories locales demandent une adaptation.

Ghani et al. montrent en 2023 que des représentations aviaires issues notamment de BirdNET et de Perch servent efficacement plusieurs tâches bioacoustiques

Tableau 1 – Comparaison des solutions retenues dans la veille. Seul BirdNET est exécuté dans l'expérimentation ; les autres lignes synthétisent les sources citées.

Modèle	Apprentissage et signal	Sorties et adaptation	Conséquence pour le choix
BirdNET [2, 3]	Supervision ; spectrogrammes ; réseau de type EfficientNet-B0 pour 2.4	Scores d'espèces, représentations et classifieur personnalisé	Analyse directe si le vocabulaire couvre la cible ; seuil à vérifier sur les données locales
Perch 2.0 [5]	EfficientNet-B3 ; corpus annotés de plusieurs taxons	Scores et représentations pour transfert	Même encodeur pour reconnaissance directe et adaptation à des catégories locales
AVES [6]	HuBERT ; forme d'onde ; prédiction d'unités masquées	Représentations audio à adapter	Choisir la configuration de préentraînement et entraîner une décision pour la tâche visée
Bird-MAE [7]	ViT ; spectrogrammes ; reconstruction masquée sur BirdSet-XCL	Ajustement du réseau ou classifieur sur représentations gelées	Comparer aussi les têtes linéaires et à prototypes avec les mêmes annotations

avec un classifieur linéaire [8]. Leur étude de 2025 précise le compromis : la distillation est favorable sur les données Xeno-canto du domaine étudié, tandis qu'une adaptation limitée du classifieur associé à BirdNET généralise mieux aux paysages sonores évalués [9]. Ajuster davantage de paramètres n'assure donc pas un meilleur transfert. Le choix porte aussi sur les données d'adaptation et sur les paramètres conservés.

AVES et Bird-MAE réduisent la dépendance aux annotations pendant le préentraînement, mais construisent des tâches différentes. AVES applique une approche HuBERT à la forme d'onde et prédit des unités acoustiques masquées, à partir de combinaisons de FSD50K, AudioSet et VGGSound [6]. Bird-MAE emploie un Vision Transformer (ViT) pour reconstruire des portions masquées de spectrogrammes, sur le sous-ensemble aviaire XCL de BirdSet [7]. Le premier vise des représentations audio généralistes ou bioacoustiques ; le second spécialise son préentraînement sur les oiseaux.

Les représentations doivent aussi être associées à une décision. Bird-MAE étudie des têtes à prototypes qui exploitent mieux ses caractéristiques gelées qu'une simple tête linéaire dans les expériences publiées [7]. Les performances dépendent ainsi de l'encodeur, du classifieur et du protocole. Les différences de données empêchent d'attribuer les écarts publiés à la seule opposition entre réseaux convolutifs et Transformers. L'auto-supervision économise des annotations de préentraînement, mais l'adaptation et l'évaluation en demandent encore.

2.2. Annotations, masquage et changement de domaine

Les enregistrements focaux de Xeno-canto indiquent principalement une espèce. Ils conviennent à la recherche d'une cible annoncée, mais renseignent mal le statut des autres sorties. Des annotations secondaires incomplètes peuvent modifier le compromis entre précision et rappel [9]. Les paysages sonores annotés de BirdSet, dont NIPS4BPlus [10, 11], et les évaluations BirdCLEF [12] permettent d'examiner les cooccurrences et les fausses alertes. Les vocabulaires et règles d'annotation doivent toutefois être harmonisés avant de comparer les modèles.

Le choix du seuil intervient ensuite : un score élevé n'est pas une mesure directe de la précision d'un inventaire. Relever le seuil écarte généralement des fausses alertes et des présences réelles [13]. Pour rechercher une espèce rare, manquer une présence et vérifier une alerte supplémentaire n'ont pas le même coût que pour dresser une liste de détections fiables. Comparer des versions au même seuil numérique décrit un réglage commun, mais pas nécessairement un même compromis entre ces erreurs.

La superposition intervient aussi à l'apprentissage : Perch 2.0 et Bird-MAE utilisent des mélanges de sources [5, 7]. Cette exposition à des cooccurrences n'établit pas une résistance au masquage à un niveau donné. Le masquage d'unités dans AVES ne correspond pas non plus à un ajout de bruit ambiant. Les sources retenues ne proposent pas une comparaison commune des modèles aux mêmes rapports signal/bruit et de mélange.

Sur le terrain, Sethi et al. règlent les seuils par espèce et par jeu à partir de détections vérifiées pour viser une précision de 90 %, sans mesurer le rappel des communautés entières [14]. Funosas et al. observent un rappel plus hétérogène que la précision selon les continents, sur 4224 enregistrements d'une minute provenant de 67 sites [15]. Ces travaux montrent pourquoi un résultat écologique utile peut coexister avec des omissions. Un changement de région modifie souvent les espèces, les ambiances et la collecte : la généralisation géographique exige de distinguer ces effets.

2.3. Maturité et contraintes d'utilisation

La disponibilité des outils intervient dans le choix. BirdNET-Analyzer propose une interface, l'analyse par lots et des classifieurs personnalisés [16]. AVES fournit des poids et des exports ; son dépôt signale un transfert de maintenance vers AVEX [17]. La fiche Bird-MAE-Base demande d'adapter la tête et signale des erreurs possibles dans les modèles distribués [18]. Le dépôt de recherche Perch indique que des parties de l'installation sont obsolètes ; l'export `perch_v2/2` demande TensorFlow 2.20 ou supérieur et un GPU, avec une variante pour le CPU [19, 20]. Ces états logiciels sont distincts des performances publiées. AVES est publié à ICASSP 2023 et Bird-MAE dans TMLR en 2025 ; Perch 2.0 est

ici cité comme prépublication, sans publication évaluée par les pairs identifiée dans les sources consultées.

Les droits du code et des poids diffèrent également. Analyzer est sous MIT, mais annonce CC BY-NC-SA 4.0 pour les modèles distribués, alors que la notice Zenodo du fichier 2.4 indique CC BY-NC 4.0. La restriction non commerciale est commune, l'obligation de partage à l'identique reste à clarifier. Pour 3.0 Preview 3.1, les documents annoncent CC BY-SA 4.0 avec des conditions jointes ; l'articulation entre usage commercial et diffusion pour recherche et évaluation reste ambiguë [4,21,22]. Perch 2.0 indique Apache 2.0 [20]. Aucun débit, pic mémoire ou coût énergétique commun n'a été mesuré dans cette étude.

Les fichiers FP32 utilisés ici occupent environ 51,7 Mo pour BirdNET 2.4 et 541,6 Mo pour 3.0. Cet écart concerne les fichiers téléchargés, pas la mémoire maximale en exécution. Le transfert sur représentations gelées conserve lui aussi le coût de l'encodeur, même si peu de paramètres sont entraînés. Pour des archives volumineuses, il faut donc vérifier le format disponible et le traitement par lots, en plus des possibilités d'adaptation ; pour un suivi continu, le débit doit encore être mesuré sur le matériel retenu.

3. Cas d'étude et protocole expérimental

3.1. Exploration et choix des données annotées

BirdNET est retenu pour étudier le seuil, le bruit et la superposition sans réentraînement ; les autres modèles sont comparés sur leurs sources. L'exploration initiale comprend 3591 enregistrements Xeno-canto, pour 296 espèces à cible exploitable. Le bruit est appliqué aux 2937 cibles reconnues, sur leur segment de score maximal : cette sélection favorise la récupération initiale. Les 1416 paires exploratoires sont mélangées sans égalisation des niveaux. Ces essais décrivent des réactions, plutôt qu'une performance multilabel supervisée.

Le corpus représente environ 51,2 heures et 96 pays, avec 3492 enregistrements à cible couverte. Les 555 cibles non retrouvées au départ et les 99 cibles non identifiées ou non couvertes sont exclues du bruit. Les effectifs sont très inégaux : 148 espèces n'ont qu'un enregistrement, 209 en ont moins de cinq, et les vingt espèces les plus représentées concentrent 59,4 % des cibles exploitables. Cette composition motive le calcul de moyennes par espèce en complément des moyennes par enregistrement.

L'évaluation annotée utilise deux sous-ensembles BirdSet [23] : NBP, issu de NIPS4BPlus, avec 539 segments et 51 espèces ; HSN, issu de *High Sierras*, avec 600 segments tirés dans 100 sources. HSN compte 333 segments sans annotation d'oiseau et 13 espèces présentes sur 21 évaluées. Les six segments par source HSN sont tirés sans remise, sans sélection par score ni par présence d'oiseau. NBP apporte surtout des extraits positifs, tandis que HSN permet aussi d'examiner les alertes sur des segments négatifs.

3.2. Comparaison des versions et réglage des seuils

BirdNET 2.4 est exécuté en simple précision sur 32 bits (FP32) avec LiteRT, 3.0 Preview 3.1 en FP32 avec ONNX Runtime. La bibliothèque BirdNET 1.1.1 découpe les deux versions en fenêtres de trois secondes. Les mêmes extraits sont fournis aux deux modèles, sans filtrage géographique. Le score d'une espèce est le maximum sur les fenêtres et les sorties rattachées à son concept taxonomique. Une espèce NBP absente de 2.4 reçoit un score nul ; les résultats sont aussi recalculés sur les 50 classes communes. Les sorties hors du vocabulaire annoté sont exclues : le test concerne un ensemble fermé de classes.

L'espèce absente de 2.4 est *Curruca cantillans*, avec 33 présences NBP. Elle est comptée comme omission, sans substitution par une espèce voisine. Neuf catégories de référence correspondent à plusieurs sorties de 3.0 après des séparations taxonomiques ; leur maximum conserve le concept annoté, avec plusieurs possibilités de franchir le seuil. Le recalcul sur les classes communes sert à vérifier si le changement de vocabulaire explique l'écart.

Une partition réserve 25 % des sources au choix du seuil, sur une grille de 0,05 à 0,95 par pas de 0,05, en maximisant le F1 micro. Le seuil est ensuite figé sur les autres sources ; les segments d'une même source HSN restent groupés. La graine est `20261008`. La précision rapporte les présences retrouvées aux prédictions retenues, le rappel aux présences annotées ; le F1 micro réunit les décomptes des espèces. Les intervalles de confiance (IC) à 95 % utilisent 2000 tirages bootstrap appariés par source. Ils sont conditionnels au seuil choisi. Cette validation est interne et rétrospective ; l'indépendance des données vis-à-vis du préentraînement n'a pas été établie.

Les seuils communs 0,10, 0,25, 0,50 et 0,75 décrivent d'abord le comportement des modèles sur tous les segments. La validation séparée répond ensuite à la question du réglage : 135 sources NBP et 25 sources HSN servent à choisir le seuil ; les 404 extraits NBP et les 450 segments des 75 sources HSN restantes servent à l'évaluation. L'appariement conserve les mêmes observations pour les deux versions, au lieu de déduire un écart du seul chevauchement de deux IC.

3.3. Perturbations avec contrôles acoustiques

Les contrôles acoustiques utilisent 40 sources positives par jeu, choisies par annotation dans le test, en conservant les omissions initiales. BirdNET 3.0 est évalué au seuil calibré de 0,05. Des bruits gaussiens ou fonds HSN enregistrés sont ajoutés à 20, 10, 5 et 0 dB, avec cinq répétitions. À 0 dB, la puissance du bruit ajouté égale celle de l'extrait entier, ambiance comprise. Les fonds proviennent de 20 sources de calibration distinctes des sources positives ; le bootstrap conserve ces groupes de fond partagé après moyenne des répétitions. La récupération est la moyenne des proportions d'espèces annotées retrouvées par extrait. Les mélanges réunissent 20 paires NBP et 19 paires HSN disjointes, à ensembles

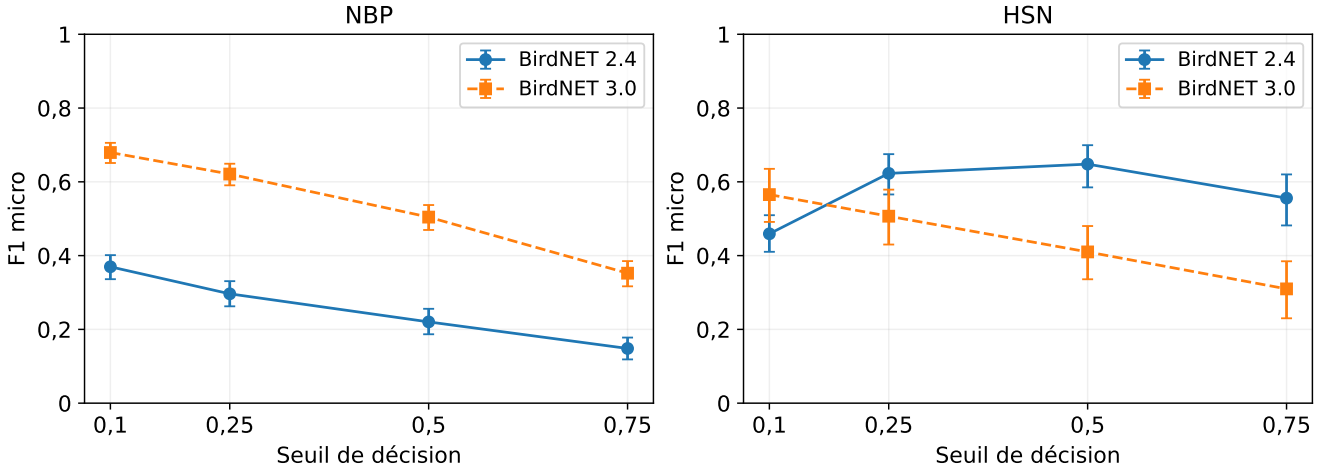


Figure 1 – F1 micro sur tous les segments aux quatre seuils communs. Les IC à 95 % regroupent les segments par source. Cette comparaison précède le réglage séparé des seuils sur la partition de calibration.

Tableau 2 – Évaluation sur des sources séparées de celles du réglage du seuil. Les IC à 95 % rééchantillonnent les sources de test au seuil fixé.

Jeu	Version	Seuil	Sources calibration / test	Précision	Rappel	F1 micro [IC 95 %]
NBP	2.4	0,05	135 / 404	0,669	0,311	0,425 [0,388 ; 0,461]
NBP	3.0	0,05	135 / 404	0,695	0,636	0,664 [0,633 ; 0,694]
HSN	2.4	0,50	25 / 75	0,849	0,533	0,655 [0,589 ; 0,716]
HSN	3.0	0,05	25 / 75	0,741	0,508	0,603 [0,533 ; 0,667]

d'espèces annotées disjoints, après égalisation des niveaux efficaces (RMS). Les coefficients 50/50, 75/25 et 90/10 sont appliqués aux deux témoins isolés et au mélange, avec un gain final commun. Le bootstrap rééchantillonne les paires.

Le SNR est réglé sur la puissance de l'extrait entier : une valeur de 0 dB n'implique pas que le bruit ait la même puissance que le chant seul. Les ratios de mélange désignent des coefficients d'amplitude après égalisation RMS, pas des proportions d'espèces ou de durée. Conserver les mêmes découpages et gains dans les témoins rend la comparaison sensible à la superposition ajoutée. Les cinq réalisations d'un bruit ne sont pas traitées comme cinq nouvelles sources indépendantes.

4. Résultats retenus

4.1. Effet du seuil et comparaison des versions

Dans l'exploration Xeno-canto, relever le seuil de 0,10 à 0,75 réduit la récupération de l'espèce principale de 84,1 à 60,0 %. Le nombre de prédictions par fenêtre passe de 98 117 à 23 583, et les catégories distinctes de 3519 à 960. Ces catégories prédites ne sont pas un inventaire validé : les étiquettes disponibles ne décrivent pas toutes les vocalisations présentes.

Au seuil 0,10, le F1 micro sur NBP atteint 0,679 pour 3.0 contre 0,370 pour 2.4, avec une différence appariée de +0,310 et un IC à 95 % de [+0,277 ; +0,344]. Sur HSN, 2.4 obtient un rappel de 0,864 et une précision de 0,313, contre 0,434 et 0,812 pour 3.0. Parmi les 333 segments sans annotation d'oiseau, 66,4 % reçoivent au moins une prédiction avec 2.4, contre 2,1 % avec 3.0. La version 3.0 est plus sélective à ce seuil sur HSN, en laissant aussi davantage de présences de côté.

Après réglage séparé des seuils (tableau 2), le F1 micro sur NBP atteint 0,425 pour 2.4 et 0,664 pour 3.0. L'écart apparié vaut +0,239, avec un IC de [+0,200 ; +0,278]. Sur HSN, les F1 valent 0,655 et 0,603, pour un écart de −0,052 et un IC de [−0,123 ; +0,016]. L'intervalle contient zéro : aucun avantage n'est établi dans cette partition, sans démonstration d'équivalence. Au seuil commun 0,50 sur l'ensemble HSN, les F1 étaient de 0,648 et 0,410. Le changement de partition empêche d'attribuer toute la réduction de l'écart au seul réglage du seuil.

La figure 1 explique pourquoi le seuil commun ne suffit pas au choix d'une version. Sur NBP, 3.0 reste devant aux quatre seuils explorés ; sur HSN, l'ordre change. Relever le seuil peut améliorer le F1 d'un modèle trop peu sélectif, puis le dégrader lorsque les omissions deviennent trop nombreuses. Le tableau 2 présente le compromis retenu pour chaque couple modèle/jeu sur des sources séparées.

4.2. Bruit et vocalisations simultanées

Sans perturbation, la récupération moyenne par extrait est de 75,5 % sur NBP et 45,0 % sur HSN. À 0 dB, elle atteint respectivement 63,8 % et 22,2 % avec le bruit gaussien, puis 70,2 % et 29,2 % avec les fonds enregistrés (figure 2). Les quatre IC appariés de l'écart avec l'original sont entièrement négatifs. L'exploration Xeno-canto retrouvait 82,5 % des cibles à 0 dB contre 99,9 % sur les segments originaux, mais sous condition de reconnaissance préalable. Les valeurs absolues ne décrivent donc pas une même sensibilité.

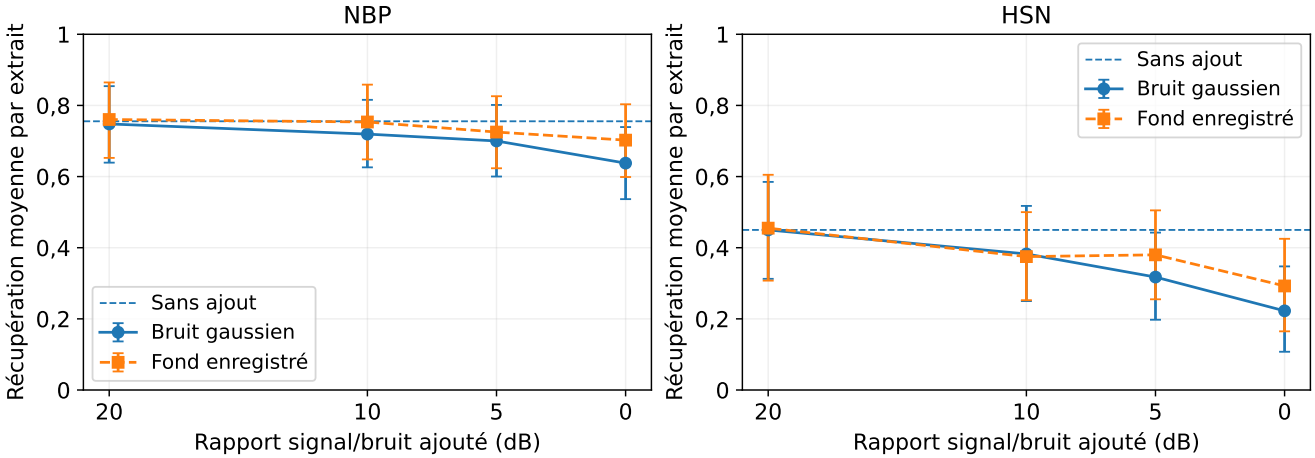


Figure 2 – Récupération moyenne des espèces annotées par extrait, BirdNET 3.0 au seuil 0,05. Les tirets horizontaux indiquent les mêmes extraits sans ajout. Les barres sont des IC à 95 %, groupés par source de fond partagé.

Dans l'exploration, le score moyen exporté passe de 0,778 à 0,568 à 0 dB. L'écart apparié vaut −0,211, avec un IC à 95 % de [−0,219 ; −0,203] ; le regroupement par espèce l'élargit à [−0,252 ; −0,181]. Le signe de la baisse est conservé dans les deux calculs. Ces scores exportés sont censurés sous le seuil 0,10, où ils sont représentés par zéro : leur moyenne décrit les sorties retenues, pas toute la réponse interne du réseau.

La récupération des deux cibles baisse aussi lors des mélanges par rapport aux témoins isolés (tableau 3). Sur NBP, elle passe de 30,0 à 20,0 puis 10,0 % entre 50/50, 75/25 et 90/10, contre 60,0 % dans les témoins à chaque ratio. Sur HSN, une seule paire sur 19 retrouve les deux cibles dans chaque mélange ; à 90/10, l'IC de l'écart atteint zéro. Ce résultat identique sur trois ratios ne démontre pas une insensibilité au niveau relatif, compte tenu des effectifs et des intervalles larges.

Dans les 1416 paires exploratoires Xeno-canto, la récupération conjointe vaut 26,8 % à 50/50, avec un IC à 95 % de [24,4 ; 29,0] %, contre 18,6 % à 90/10. Ces mélanges sans égalisation ne séparent pas l'effet du ratio de celui des niveaux initiaux. Les essais BirdSet avec témoins isolés apportent cette comparaison contrôlée sur un effectif plus réduit.

5. Interprétation et discussion critique

5.1. Ce que les perturbations apprennent sur la robustesse

Le biais de sélection explique une partie de l'écart entre les deux volets. L'exploration Xeno-canto retient les cibles déjà reconnues et leur meilleur segment, alors que les contrôles BirdSet gardent les omissions initiales. J'en retiens qu'un taux élevé sous bruit n'est interprétable qu'en connaissant son dénominateur et sa sélection. La baisse à 0 dB persiste sur les extraits choisis par annotation : elle ne dépend donc pas uniquement du premier biais. Les deux expériences confortent ce constat dans leurs conditions, sans autoriser la mise en commun de leurs taux.

La même attention à l'agrégation vaut pour le corpus initial : à 0 dB, la récupération vaut 82,5 % en donnant le même poids aux enregistrements, contre 78,0 % en donnant le même poids aux espèces. L'écart est cohérent avec la forte concentration des données. Ajouter des exemples d'une espèce déjà dominante augmente la précision de sa description, mais renseigne peu les espèces rares du corpus.

Les fonds enregistrés donnent des récupérations moyennes plus élevées que le bruit gaussien à 0 dB, à puissance ajoutée contrôlée. Une explication possible est leur répartition spectrale et temporelle différente ; elle n'a pas été mesurée. Les IC calculés portent sur l'écart à l'original, sans test apparié direct entre types de bruit. Les fonds ne sont ni caractérisés comme pluie, vent ou insectes, ni certifiés exempts de toute vocalisation. Un SNR identique ne suffit donc pas à qualifier une difficulté acoustique identique.

Les témoins isolés distinguent les omissions présentes avant mélange de la difficulté ajoutée par la superposition. L'écart négatif à 50/50 est compatible avec un effet de masquage supplémentaire, mais le découpage et l'égalisation portent sur les extraits entiers, sans séparer les chants de leurs ambiances. Les augmentations par mélanges de Perch 2.0 et Bird-MAE répondent à ce problème pendant l'apprentissage [5,7]. Elles constituent un point de comparaison pertinent, dont l'efficacité relative n'est pas mesurée ici.

5.2. Choisir un modèle et un seuil pour un usage donné

L'avantage de 3.0 sur NBP persiste après réglage du seuil. À seuil commun 0,10, la restriction aux 50 classes partagées donnait également des F1 de 0,678 pour 3.0 et 0,380 pour 2.4 : l'écart ne se réduit pas à l'espèce absente de 2.4. HSN montre une autre situation, où l'écart dépend davantage de la décision. Cela rejoint les compromis décrits par Pérez-Granados [13]. Pour une migration de version, je conserverais les données de validation, réviserais le seuil et vérifierais les correspondances taxonomiques, plutôt que de transposer un réglage numérique à l'identique.

La calibration désigne ici le choix d'un seuil, pas une transformation des scores en probabilités calibrées. Trois

Tableau 3 – Récupération conjointe à 50/50 dans les témoins isolés et le mélange, sur 20 paires NBP et 19 paires HSN. L'écart mélange moins témoins est en points de pourcentage ; les IC à 95 % rééchantillonnent les paires disjointes.

Jeu	Témoins isolés	Mélange	Écart (points) [IC 95 %]
NBP	60,0 %	30,0 %	−30,0 [−50,0 ; −10,0]
HSN	26,3 %	5,3 %	−21,1 [−42,1 ; −5,3]

des quatre couples modèle/jeu retiennent 0,05, borne inférieure explorée ; le meilleur seuil de la grille n'est pas nécessairement optimal sur tout l'intervalle des scores. Le F1 micro privilégie les présences fréquentes : sur les 11 espèces HSN présentes dans le test, le F1 macro vaut 0,509 pour 2.4 et 0,560 pour 3.0, contrairement à l'ordre micro. Une recherche centrée sur une espèce rare peut donc demander un autre réglage. Une partition unique et des IC conditionnels au seuil ne mesurent pas la variabilité de toute la procédure de sélection.

Le choix technologique dépasse cette comparaison locale. Pour analyser des archives dans un vocabulaire couvert, BirdNET fournit une chaîne directement utilisable ; 3.0 reste néanmoins une préversion dont les conditions de distribution demandent clarification. Pour de nouvelles classes ou des types de cris, un classifieur sur représentations gelées offre un premier essai avant l'ajustement complet, cohérent avec les travaux de transfert [8, 9]. AVES et Bird-MAE apportent d'autres représentations à comparer avec les mêmes annotations et le même protocole. La maturité des outils, les licences et le coût d'extraction doivent être examinés séparément des performances annoncées dans des évaluations différentes.

5.3. Portée de l'étude et verrous qui subsistent

Le test se limite aux catégories annotées ; les alertes hors vocabulaire ne sont pas comptabilisées. Les correspondances taxonomiques sont en partie asymétriques, et l'usage d'un maximum sur plusieurs sorties pour certains concepts de 3.0 ne rend pas les vocabulaires strictement identiques. Les 40 extraits par jeu et les 20 sources de fond restreignent aussi la précision des contrôles acoustiques. Les intervalles décrivent le corpus observé, sans corriger toutes les dépendances entre sites ou auteurs.

NBP et HSN ne partagent aucune espèce dans leurs vocabulaires évalués ; les métadonnées disponibles ne permettent pas une comparaison multisite contrôlée. L'écart entre jeux combine donc des effets taxonomiques, acoustiques et géographiques. L'étude ne tranche pas la question du transfert vers une nouvelle région, ni celle d'un éventuel recouvrement avec le préentraînement. Les évaluations de Sethi et de Funosas montrent l'intérêt d'une validation locale et de plusieurs sites [14, 15], que cette expérimentation réduite ne remplace pas.

6. Conclusion et prise de recul

Les modèles permettent d'automatiser une partie de l'identification des oiseaux, mais le bruit, les superpositions et les données de référence conditionnent la portée de leurs sorties. Les expériences établissent une dégradation dans les perturbations étudiées ; elles ne classent pas toutes les technologies. BirdNET 3.0 présente un avantage sur NBP ; sur HSN, le choix dépend du seuil et du critère. La généralisation géographique demeure non résolue par les données utilisées.

Je retiens qu'il faut évaluer ensemble modèle, annotations et décision. Pour un usage direct, je partirais d'un modèle distribué et d'un ensemble local annoté ; pour des catégories absentes, d'une adaptation de représentations. La priorité serait un test multisite sur des espèces communes, avec des sites ou campagnes réservés dès le départ à l'évaluation. Modèles directs et adaptations seraient comparés avec le même budget d'annotations. Pour Bird-MAE, j'inclurais une tête à prototypes en plus d'une tête linéaire.

Les contrôles acoustiques gagneraient à utiliser des fonds caractérisés et davantage de paires réannotées après découpage. Le débit, la mémoire et la stabilité restent à mesurer sur le matériel visé. Accumuler uniquement des sons focaux ne résoudrait ni le biais de sélection, ni les erreurs d'un inventaire ouvert.

Références

[1] Dan Stowell. Computational bioacoustics with deep learning : a review and roadmap. *PeerJ*, 10 :e13152, 2022. doi:10.7717/peerj.13152.

[2] Stefan Kahl, Connor M. Wood, Maximilian Eibl, and Holger Klinck. BirdNET : A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61 :101236, 2021. doi:10.1016/j.ecoinf.2021.101236.

[3] BirdNET Team. BirdNET : official model documentation. Documentation officielle des modèles. Consultation : 15 octobre 2026 ; modèle acoustique 3.0 décrit comme une préversion.

[4] Stefan Kahl, Connor Wood, and Holger Klinck. BirdNET model V2.4. Zenodo, fichiers de modèles, 2025. doi:10.5281/zenodo.15050749 ; consultation : 15 octobre 2026.

[5] Bart van Merriënboer, Vincent Dumoulin, Jenny Hamer, Lauren Harrell, Andrea Burns, and Tom Denton. Perch 2.0 : The bittern lesson for bioacoustics. arXiv:2508.04665v2, 2025. Prépublication, version 2 du 5 janvier 2026.

[6] Masato Hagiwara. AVES : Animal vocalization encoder based on self-supervision. In *ICASSP 2023 – IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 1–5. IEEE, 2023. doi:10.1109/ICASSP49357.2023.10095642 ; prépublication initiale en 2022.

[7] Lukas Rauch, René Heinrich, Ilyass Moummad, Alexis Joly, Bernhard Sick, and Christoph Scholz. Can masked autoencoders also listen to birds ? *Transactions on Machine Learning Research*, 2025. Version publiée en août 2025.

[8] Burooj Ghani, Tom Denton, Stefan Kahl, and Holger Klinck. Global birdsong embeddings enable superior transfer learning for bioacoustic classification. *Scientific Reports*, 13 :22876, 2023. doi:10.1038/s41598-023-49989-z.

[9] Burooj Ghani, Vincent J. Kalkman, Bob Planqué, Willem-Pier Vellinga, Lisa Gill, and Dan Stowell. Impact of transfer learning methods and dataset characteristics on generalization in birdsong classification. *Scientific Reports*, 15 :16273, 2025. doi:10.1038/s41598-025-00996-2.

[10] Veronica Morfi, Yves Bas, Hanna Pamuła, Hervé Glotin, and Dan Stowell. NIPS4Bplus : a richly annotated birdsong audio dataset. *PeerJ Computer Science*, 5 :e223, 2019. doi:10.7717/peerj-cs.223.

[11] Lukas Rauch, Raphael Schwinger, Moritz Wirth, René Heinrich, Denis Huseljic, Marek Herde, Jonas Lange, Stefan Kahl, Bernhard Sick, Sven Tomforde, and Christoph Scholz. BirdSet : A large-scale dataset for audio classification in avian bioacoustics. In *International Conference on Learning Representations (ICLR)*, 2025. Actes officiels.

[12] LifeCLEF. BirdCLEF+ 2025. Présentation du défi, 2025. Consultation : 15 octobre 2026.

[13] Cristian Pérez-Granados. BirdNET : applications, performance, pitfalls and future opportunities. *Ibis*, 165(3) :1068–1075, 2023. doi:10.1111/ibi.13193.

[14] Sarab S. Sethi, Avery Bick, Ming-Yuan Chen, et al. Large-scale avian vocalization detection delivers reliable global biodiversity insights. *Proceedings of the National Academy of Sciences*, 121(33) :e2315933121, 2024. doi:10.1073/pnas.2315933121.

[15] David Funosas, Esther Sebastián-González, Jon Morant, et al. A global assessment of BirdNET performance : Differences among continents, biomes, and species. *Ecological Indicators*, 182 :114550, 2026. doi:10.1016/j.ecolind.2025.114550.

[16] BirdNET Team. BirdNET-Analyzer. Dépôt logiciel. Consultation : 15 octobre 2026.

[17] Earth Species Project. AVES : Animal vocalization encoder based on self-supervision. Dépôt logiciel. Consultation : 15 octobre 2026.

[18] DBD Research Group. Bird-MAE-Base : Can masked autoencoders also listen to birds ? Fiche de modèle. Consultation : 15 octobre 2026.

[19] Google Research. Perch. Dépôt logiciel. Consultation : 15 octobre 2026.

[20] Google. Perch. Fiche de modèle. Modèle 2.0 ; consultation : 15 octobre 2026.

[21] Mario Lasseck, Maximilian Eibl, Holger Klinck, and Stefan Kahl. BirdNET+ V3.0 model developer preview. Zenodo, Preview 3.1 de juin 2026, 2026. doi:10.5281/zenodo.20703646 ; notice et conditions jointes ; consultation : 15 octobre 2026.

[22] BirdNET Team. BirdNET+ V3.0 developer preview. Dépôt logiciel et conditions d'utilisation. Consultation : 15 octobre 2026.

[23] DBD Research Group. BirdSet : data, metadata and documentation. Données et documentation. Consultation : 15 octobre 2026.