Carnet de recherche

Reconnaissance acoustique des oiseaux
par apprentissage profond

Maxime DRÉAN
Master 2 – Informatique 2349

Septembre – octobre 2026

1 Lectures et recherches

Le sujet de départ porte sur l'identification automatique des oiseaux dans des enregistrements naturels. J'ai retenu trois difficultés : le bruit ambiant, les vocalisations simultanées et le changement de région. La question de veille est donc : dans quelle mesure les modèles d'apprentissage profond permettent-ils de détecter et d'identifier les espèces malgré ces conditions ? Le périmètre comprend les chants, les cris, les modèles et les données d'évaluation ; il laisse de côté la localisation spatiale et l'estimation d'abondance.

La revue de Stowell a servi à situer les méthodes et les difficultés de la bioacoustique automatique [1]. BirdNET a fourni un premier exemple de système utilisable, et BirdSet un cadre pour comparer des modèles sur des données aviaires [2, 3]. Xeno-canto, Macaulay Library et BirdCLEF ont été repérés comme ressources possibles. Xeno-canto a été retenu pour les premiers essais ; BirdSet a ensuite fourni les données annotées nécessaires à une évaluation plus précise.

Les mots-clés ont suivi cette progression : *bird sound recognition*, *BirdNET*, *bioacoustics deep learning*, puis *noise robustness*, *overlapping vocalizations* et *soundscapes*. Le questionnement s'est ensuite étendu au transfert avec *audio embeddings*, *self-supervised learning* et *domain generalization*. Les lectures ont été prolongées au fil des essais, notamment lorsque les résultats ont soulevé la question du seuil et du changement de jeu de données.

Les travaux de Ghani et al. ont orienté la comparaison vers les représentations réutilisables et les paramètres réellement ajustés [4, 5]. AVES, Bird-MAE et Perch 2.0 ont été retenus pour comparer des objectifs de préentraînement et des modes d'adaptation différents [6–8]. Les évaluations de Sethi et de Funosas ont complété cette lecture par les conditions d'usage sur le terrain [9, 10]. Les dépôts et fiches de modèles ont servi à vérifier les formats, les outils disponibles et les licences. La synthèse retient surtout les travaux qui éclairent ces choix, plutôt qu'une succession de descriptions de modèles.

2 Première expérimentation

J'ai choisi BirdNET pour disposer d'un modèle préentraîné et tester directement l'effet du bruit, des mélanges et du seuil. Les essais reposent d'abord sur 3 591 enregistrements Xeno-canto. L'espèce principale annoncée fournit une cible à rechercher ; les autres sorties sont conservées pour explorer le comportement du modèle.

L'expérience de bruit porte sur 2 937 enregistrements dont la cible est retrouvée au départ. Le segment où son score est maximal reçoit un bruit gaussien à 20, 10, 5 et 0 dB, avec cinq réalisations par niveau. Les mélanges portent sur 1 416 paires, aux coefficients 50/50, 75/25 et 90/10. Un autre essai fait varier le seuil pour observer quelles sorties sont conservées.

La collecte et l'analyse ont été organisées par lots pour reprendre le traitement sans recommencer les calculs terminés. Les difficultés d'exécution ont concerné notamment CUDA/cuDNN et les entrées ONNX de durée variable. Un signal non silencieux a servi à vérifier le fonctionnement de l'inférence. Le notebook a été conservé pour réunir les tableaux, les figures et les observations ; les calculs ont été regroupés dans l'application Python.

Les premières sorties montrent une diminution des scores sous bruit et une récupération conjointe plus difficile dans les mélanges. Elles font surtout apparaître un problème de protocole : sélectionner une cible déjà reconnue et son meilleur segment favorise le point de départ. L'étiquette principale Xeno-canto ne permet pas non plus de classer toutes les autres prédictions en présences réelles ou en fausses alertes. J'ai donc complété l'exploration par des données annotées et des témoins acoustiques.

3 Amélioration de l'expérimentation

Deux sous-ensembles de BirdSet ont été retenus : NBP, issu de NIPS4BPlus, et HSN, issu de *High Sierras*. NBP apporte 539 extraits annotés ; HSN apporte 600 segments provenant de 100 sources, dont 333 segments sans annotation d'oiseau. Ces derniers permettent d'observer les alertes en l'absence de présence de référence. BirdNET 2.4 et 3.0 sont comparés sur les mêmes extraits, sans filtrage géographique.

L'harmonisation des espèces a demandé de rapprocher les annotations des vocabulaires des deux versions. Une espèce absente de 2.4 est comptée comme omission ; un second calcul porte sur les classes communes. La comparaison à seuil identique est complétée par un réglage propre à chaque couple modèle/jeu : 25 % des sources servent au choix du seuil, les autres à l'évaluation. Les segments d'un même enregistrement HSN restent groupés. Les intervalles de confiance sont calculés par bootstrap apparié par source.

Le protocole acoustique a également été revu. Les 40 extraits positifs de chaque jeu sont choisis à partir des annotations, en gardant les omissions initiales. Des fonds enregistrés complètent le bruit gaussien. Pour les mélanges, les niveaux efficaces sont égalisés et les deux signaux isolés sont évalués avec les mêmes gains que dans le mélange. Les 20 paires NBP et 19 paires HSN permettent ainsi de comparer la récupération conjointe avant et après superposition.

Cette seconde étape a changé l'interprétation des essais. BirdNET 3.0 obtient un meilleur F1 sur NBP ; sur HSN, le seuil modifie fortement le compromis entre omissions et fausses alertes. Après réglage séparé, aucun avantage n'est établi sur HSN dans la partition retenue. Les témoins confirment une baisse sous les perturbations étudiées, y compris lorsque les extraits sont choisis par annotation. La variabilité géographique reste discutée à partir des publications : les différences entre NBP et HSN combinent aussi des espèces et des ambiances différentes.

4 Rédaction du rapport final

Le rapport final est organisé autour de la question de veille, de la comparaison des méthodes et des résultats qui aident à choisir un outil. L'état de l'art distingue la reconnaissance directe du transfert de représentations, puis relie ces méthodes aux annotations, au masquage et au changement de domaine. Les descriptions détaillées du code sont laissées dans le rendu de l'expérimentation.

Pour la partie expérimentale, j'ai retenu la comparaison des versions et des seuils, le bruit ajouté et les mélanges avec témoins. Le corpus Xeno-canto explique le point de départ et l'évolution du protocole. Les tableaux et figures mettent en avant les résultats utiles à l'argumentation, avec les effectifs et les intervalles nécessaires à leur lecture.

La discussion confronte les observations aux travaux sur le transfert et aux évaluations de terrain. Elle distingue les résultats mesurés des explications possibles, par exemple pour l'écart entre bruit gaussien et fonds enregistrés. La conclusion revient au choix conjoint du modèle, des données et du

seuil. Les prolongements retenus sont un test multisite sur des espèces communes et une comparaison d'adaptations avec le même budget d'annotations.

Références

[1] Dan Stowell. Computational bioacoustics with deep learning : a review and roadmap. *PeerJ*, 10 :e13152, 2022. doi:10.7717/peerj.13152.

[2] Stefan Kahl, Connor M. Wood, Maximilian Eibl, and Holger Klinck. BirdNET : A deep learning solution for avian diversity monitoring. *Ecological Informatics*, 61 :101236, 2021. doi:10.1016/j.ecoinf.2021.101236.

[3] Lukas Rauch, Raphael Schwinger, Moritz Wirth, René Heinrich, Denis Huseljic, Marek Herde, Jonas Lange, Stefan Kahl, Bernhard Sick, Sven Tomforde, and Christoph Scholz. BirdSet : A large-scale dataset for audio classification in avian bioacoustics. In *International Conference on Learning Representations (ICLR)*, 2025. Actes officiels.

[4] Burooj Ghani, Tom Denton, Stefan Kahl, and Holger Klinck. Global birdsong embeddings enable superior transfer learning for bioacoustic classification. *Scientific Reports*, 13 :22876, 2023. doi:10.1038/s41598-023-49989-z.

[5] Burooj Ghani, Vincent J. Kalkman, Bob Planqué, Willem-Pier Vellinga, Lisa Gill, and Dan Stowell. Impact of transfer learning methods and dataset characteristics on generalization in birdsong classification. *Scientific Reports*, 15 :16273, 2025. doi:10.1038/s41598-025-00996-2.

[6] Masato Hagiwara. AVES : Animal vocalization encoder based on self-supervision. In *ICASSP 2023 – IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 1–5. IEEE, 2023. doi:10.1109/ICASSP49357.2023.10095642 ; prépublication initiale en 2022.

[7] Lukas Rauch, René Heinrich, Ilyass Moummad, Alexis Joly, Bernhard Sick, and Christoph Scholz. Can masked autoencoders also listen to birds ? *Transactions on Machine Learning Research*, 2025. Version publiée en août 2025.

[8] Bart van Merriënboer, Vincent Dumoulin, Jenny Hamer, Lauren Harrell, Andrea Burns, and Tom Denton. Perch 2.0 : The bittern lesson for bioacoustics. arXiv:2508.04665v2, 2025. Prépublication, version 2 du 5 janvier 2026.

[9] Sarab S. Sethi, Avery Bick, Ming-Yuan Chen, et al. Large-scale avian vocalization detection delivers reliable global biodiversity insights. *Proceedings of the National Academy of Sciences*, 121(33) :e2315933121, 2024. doi:10.1073/pnas.2315933121.

[10] David Funosas, Esther Sebastián-González, Jon Morant, et al. A global assessment of BirdNET performance : Differences among continents, biomes, and species. *Ecological Indicators*, 182 :114550, 2026. doi:10.1016/j.ecolind.2025.114550.